Ciencia de Datos Aplicada - Segundo Cuatrimestre 2025

Sistema de predicción de resultados de carreras de Fórmula 1

Uriel Arias - Cristian Tepedino

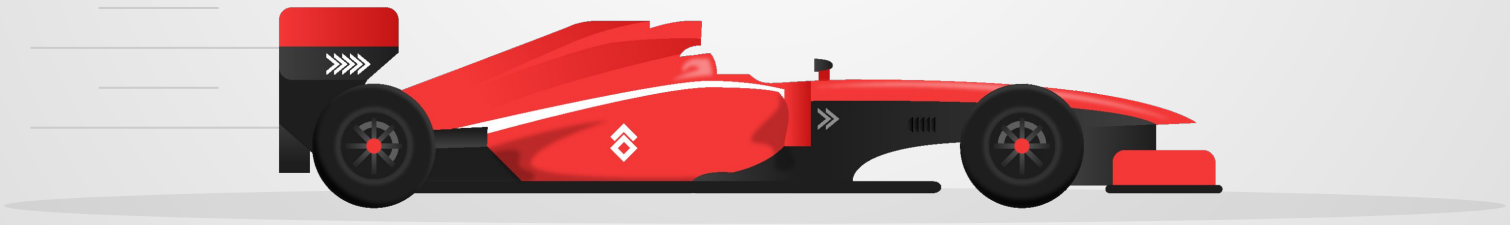

Contenido de la presentación

01

Introducción

Descripción del problema y la solución planteada

02

Datos

Descripción del origen de los datos y transformaciones realizadas.

03

Metodología

Enfoques para abordar el problema y modelos utilizados.

04

Resultados

Evaluación de los modelos en base a métricas y gráficos representativos.

05

Conclusiones

Repaso de los resultados y las limitaciones encontradas.

01

Introducción

El mundo de la Fórmula 1 y la importancia de los resultados.

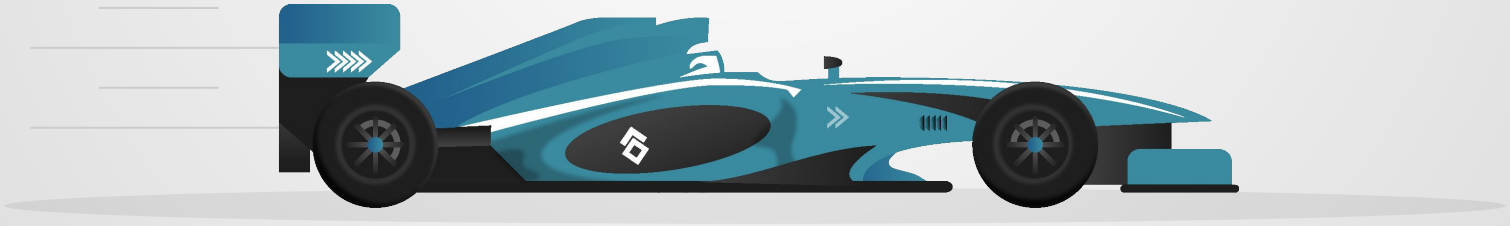

¿Qué es la Fórmula 1?

Es la **máxima categoría del automovilismo a nivel mundial**, caracterizada por su excelencia en innovación tecnológica aplicada a un monoplaza y todo lo que rodea a sus carreras.

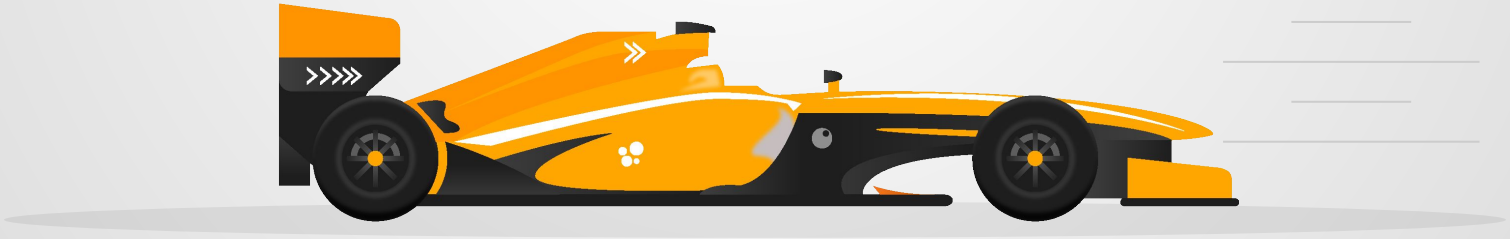

Algunos datos relevantes

- **10* equipos (*constructores*)** que compiten durante la temporada con **2 pilotos**. **11 a partir de 2026*

- Se disputan **2 campeonatos**: el de pilotos y el de constructores.

- Cada temporada consta de **20+ carreras en diversos circuitos** alrededor del mundo con **condiciones de pista** y **clima** diferentes.

Algunos datos relevantes

- Se cuenta con 2 tipos de carreras que permiten sumar puntos: las ***sprint*** (formato reducido) y los ***grandes premios*** (tradicionales).

- Cada fin de semana (que no cuenta con sprint) consta de **3 sesiones de prácticas libres**, 1 **sesión de clasificación** y 1 **carrera** (el gp en sí).

- La **telemetría de datos** es clave para analizar el **rendimiento** de los monoplazas entre sesiones y tomar **decisiones estratégicas**.

Max Verstappen: Gran Premio de Sao Paulo 2025

Resultado de Clasificación: P17

<u>Decisión del equipo</u>: Cambio de motor + UP

Nueva posición de largada: PitLane (Penalización)

Resultado de Carrera: P3

Problema: ¿Cómo predecir los resultados del domingo considerando el resultado en clasificación y otras variables?

Es clave para los equipos poder entender el **rendimiento potencial** del auto y del piloto desde la posición de salida (obtenida de la clasificación) para **elegir** entre estrategias más conservadoras o arriesgadas.

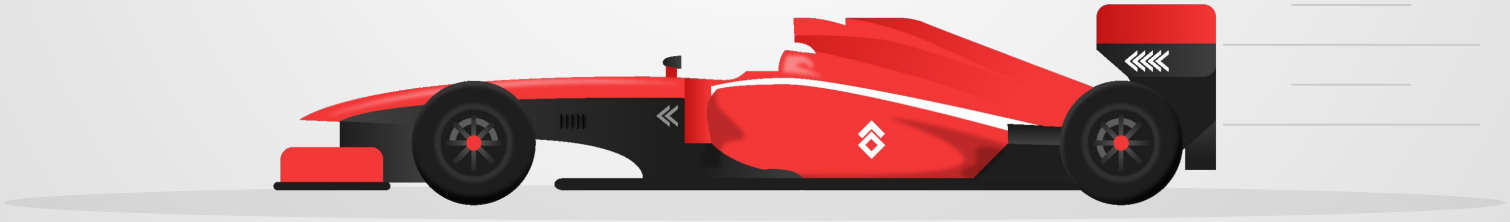

Solución propuesta: modelo de predicción

- Queremos poder ingresar como datos el **circuito,** el **clima del día de la carrera** y métricas del **rendimiento del piloto y el constructor** al que pertenece.

- Buscamos poder **predecir** si el piloto ganará, quedará en el podio o en otra posición

02

Datos

Como armamos nuestro dataset y qué transformaciones realizamos

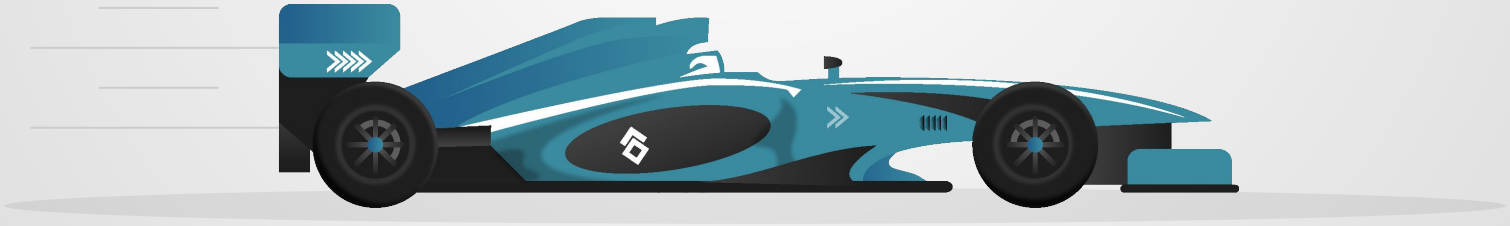

Fuentes de Datos

- Se obtuvo un dataset con información histórica (1950 - 2024) de carreras y participantes de F1. Se obtuvó el dataset de Kaggle, que compila los datos previamente disponibles en la API de Ergast.

- Complementamos el dataset con información climática sobre el momento de la carrera. Se obtuvo mediante la API de FastF1.

Variable Objetivo

- Nuestro dataset nos brinda información sobre el puesto en que finaliza cada corredor en la carrera.

- Como nuestro modelo no busca saber la posición exacta, creamos una variable clasificatoria que se ajusta a nuestro objetivo
    - 1er puesto -> Winner
    - 2do o 3er puesto -> Podium
    - El resto -> No Podium

Feature Engineering

Usando la información del dataset, construimos las siguientes features derivadas:

- ELO del piloto y del constructor
- Gap de clasificación
- Gap vs compañeros de equipo (en clasificación y en carrera)

Split en Train y Test

- Separamos el dataset en carreras hasta 2022 para entrenamiento y después de 2022 para test
- Refleja la realidad de las predicciones
- No usamos información del futuro para “predecir” el pasado

03

Metodología

Enfoques para abordar el problema y descripción de los modelos utilizados.

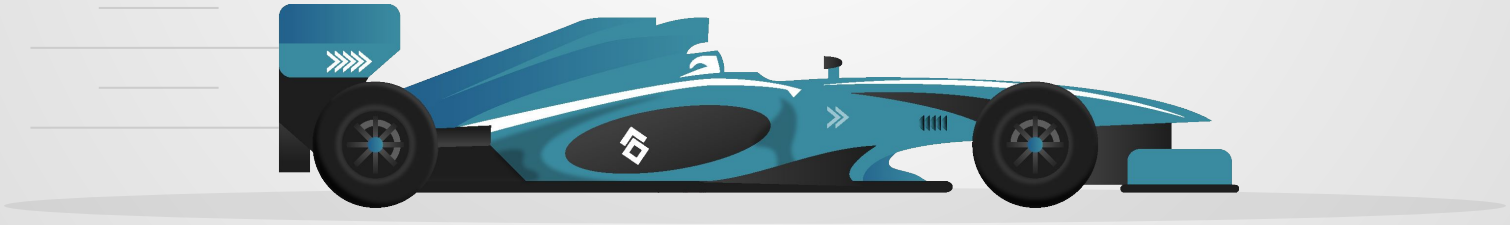

Enfoques evaluados

Si bien la tarea principal es la de predecir considerando como objetivo las 3 categorías mencionadas, se abordó la solución de dos formas:

- Como un **problema de clasificación "puro"**.
- Como un **problema de regresión** cuyos resultados luego se clasifican en cada categoría.

Los hiperparametros de los modelos de clasificación se optimizaron mediante técnicas automatizadas.
En los de regresión los hiperparámetros fueron seleccionados manualmente variando los tamaños de procesamiento y de neuronas por capa.

Modelos Utilizados

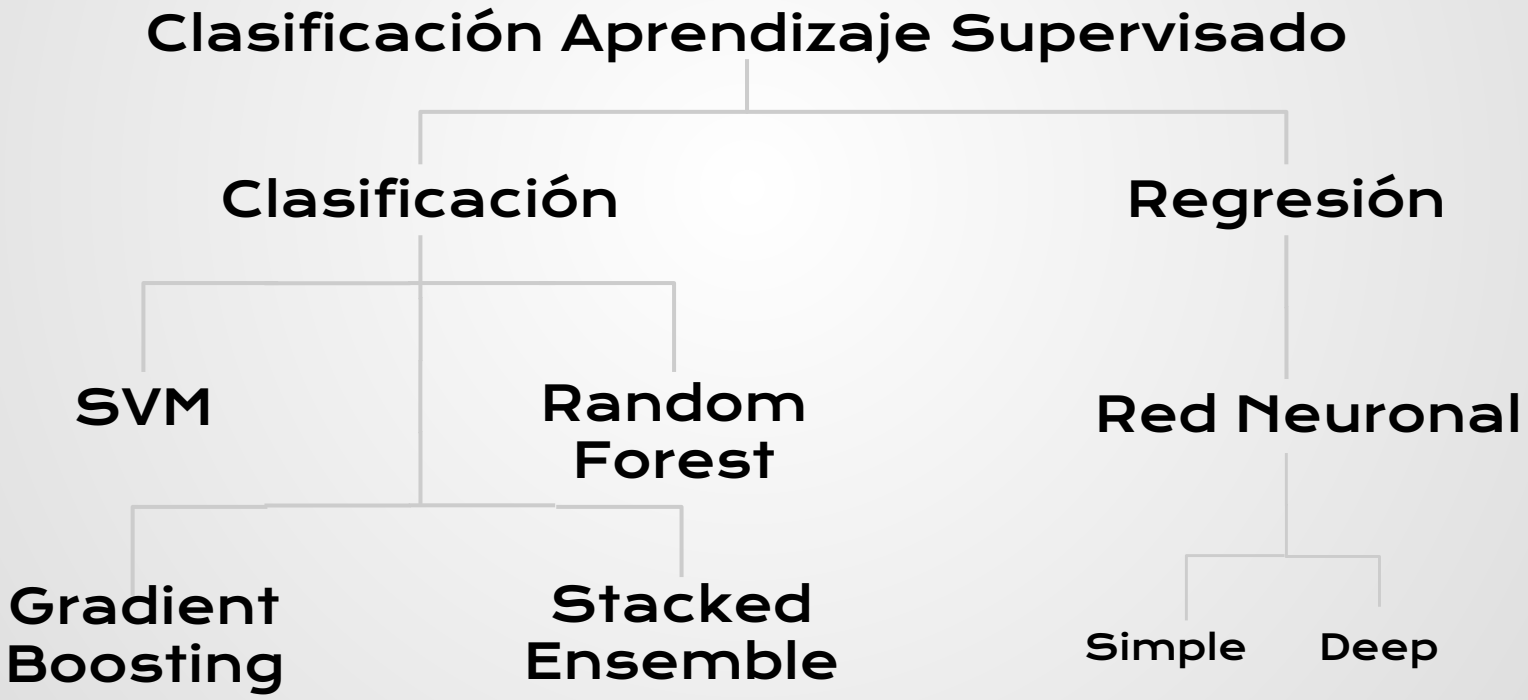

04

Resultados

Evaluación de los modelos en base a métricas y gráficos representativos.

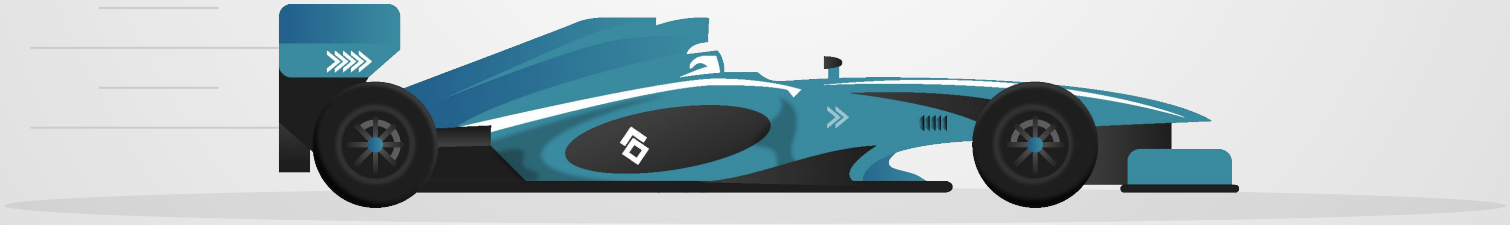

Métricas utilizadas

- **Macro F1-Score:** Permite adaptar la métrica de F1-score a diversas clases, lo que permite un balance entre captar los casos positivos (recall) y evitar los falsos positivos(precision).

$$\text{Macro F1 Score} = \frac{\sum_{i=1}^{n} \text{F1 Score}_i}{n}$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

- **Accuracy Promedio:** Permite calcular la proporción promedio de predicciones correctas respecto del total para cada categoría.

$$Accuracy = \frac{Clasificaciones\ Correctas}{Todas\ las\ clasificaciones}$$

- **Mean Absolute Error (MAE):** Permite calcular la diferencia absoluta entre la posición predicha respecto de la real.

$$MAE = \frac{1}{N} \sum_{i=0}^{N} |y_i - \hat{y}_i|$$

Comparación de Modelos de clasificación

Modelo	Macro F1-Score	Accuracy
LightGBM	0,7648	0,9042
Random Forest	0,7631	0,9013
Modelo ensamble	0,7603	0,8921
SVM	0,6200	0,8759

Resultados obtenidos sobre un test set de 919 entradas con todas las carreras de las temporadas 2023 y 2024.

Comparación de Modelos de Regresión

Modelo	Macro F1-Score	MAE
SimpleMLPRegressor (Medium)	0,5100	2,1637
DeepMLPRegressor (Small)	0,3070	2,1687
SimpleMLPRegressor (Small)	0,4850	2,2554
SimpleMLPRegressor (Tiny)	0,3960	2,3874

Resultados obtenidos sobre un test set de 919 entradas con todas las carreras de las temporadas 2023 y 2024.

Modelo seleccionado: LightGBM

	Precision	Recall	F1 Score	Support
No Podium	0,97	0,93	0,95	781
Podium	0,56	0,73	0,63	92
Winner	0,68	0,74	0,71	46
Accuracy			0,90	919
Macro avg	0,74	0,80	0,76	919
Weighted avg	0,92	0,90	0,91	919

Matriz de Confusión

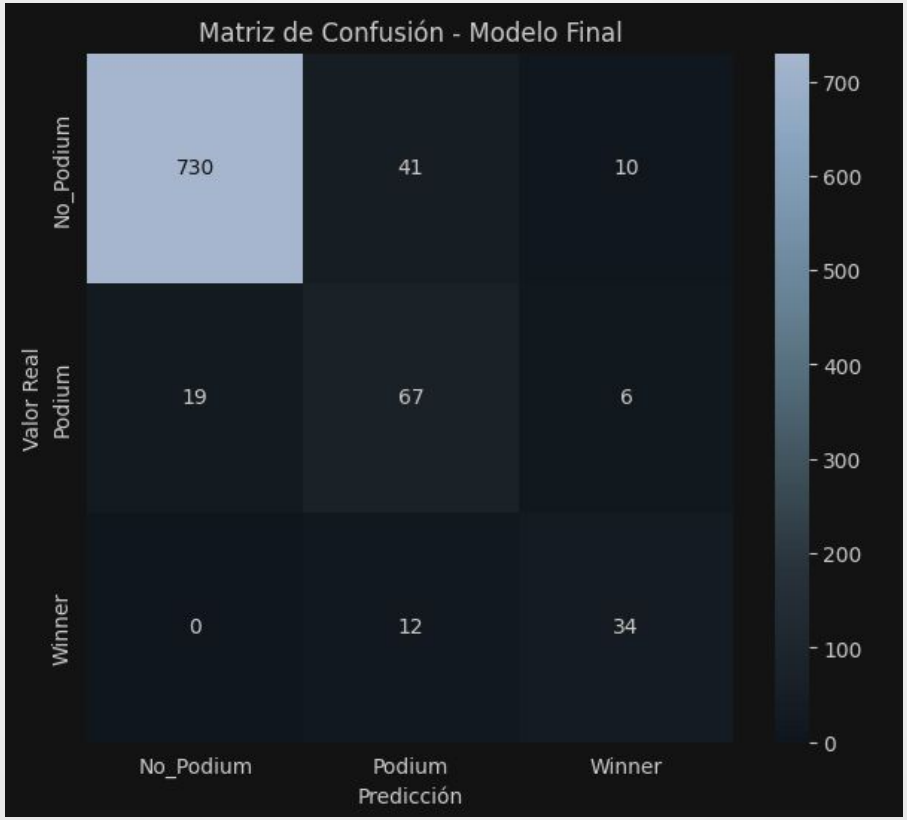

Matriz de Confusión Normalizada

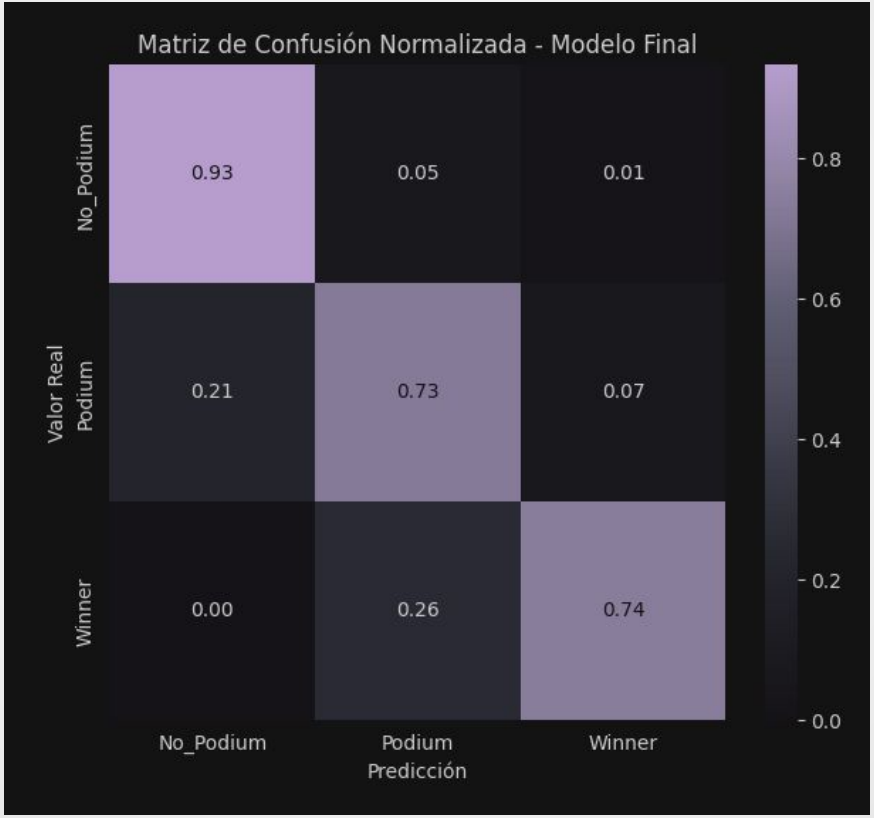

Importancia de Features

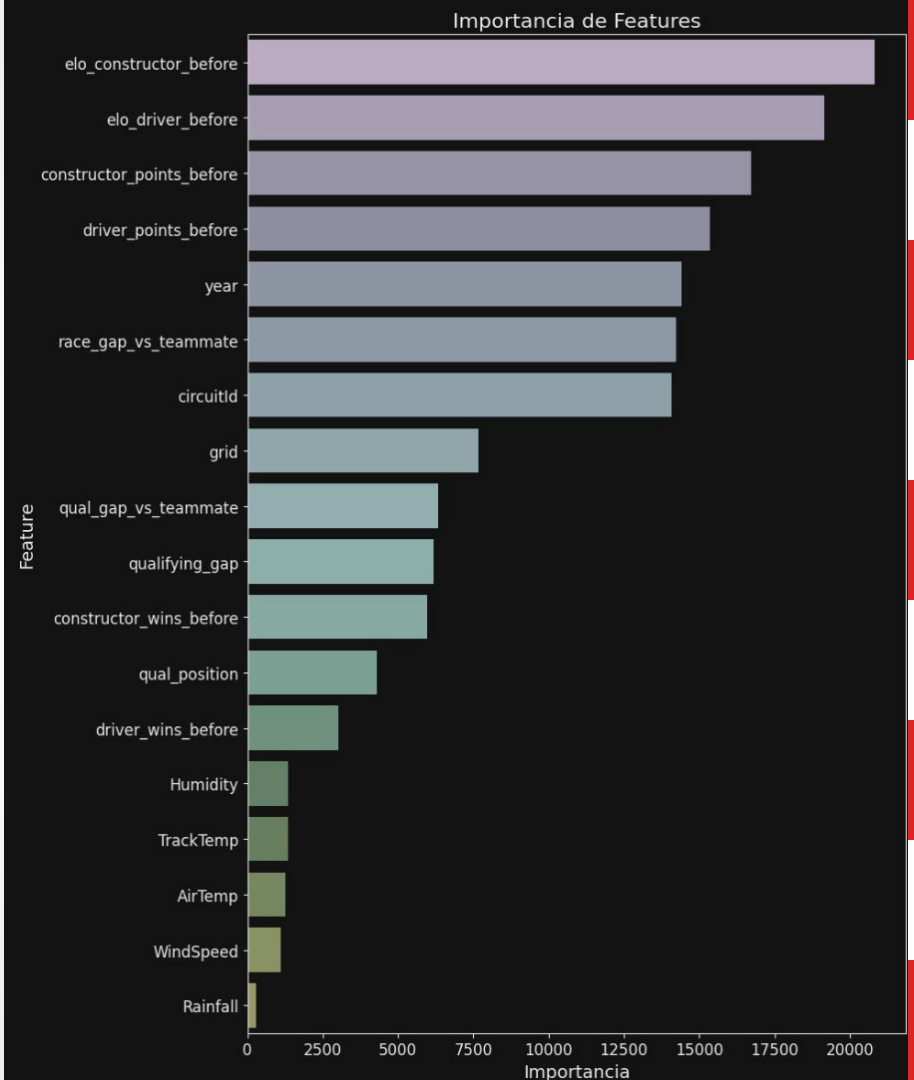

Performance por Año

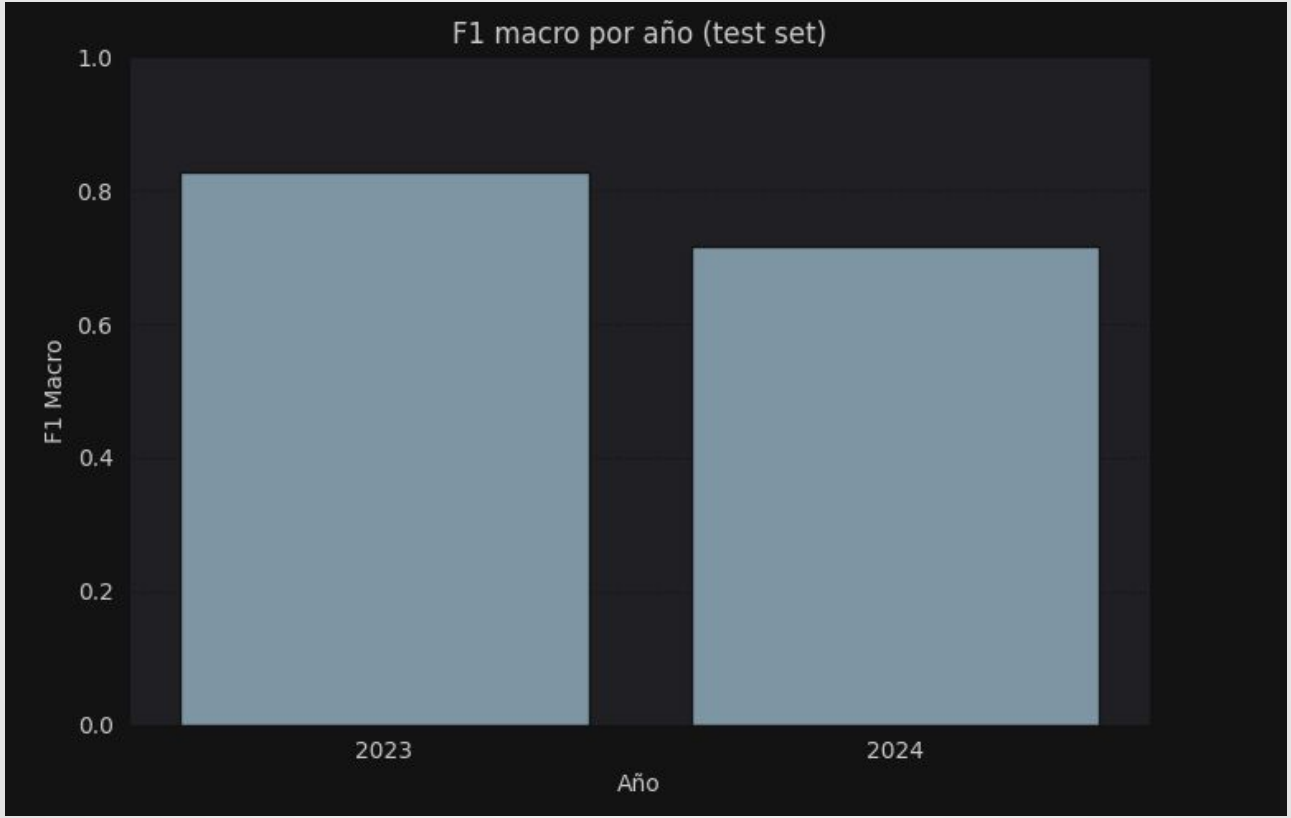

05

Conclusiones

Repaso de los resultados y las limitaciones encontradas.

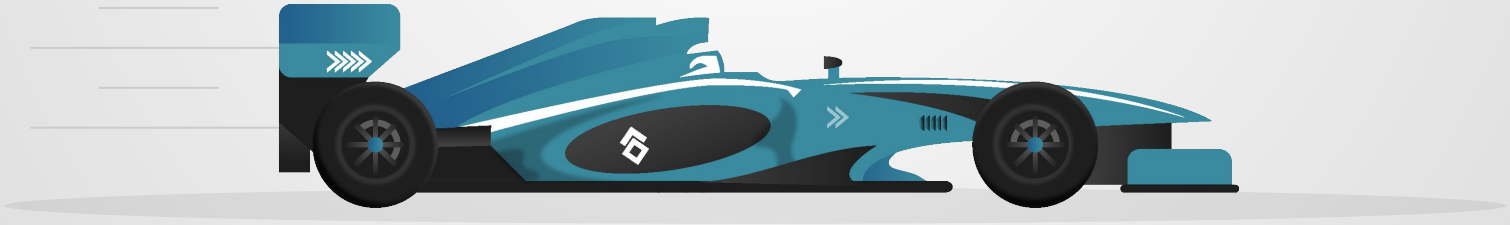

Reflexiones

- Los resultados obtenidos son buenos, considerando la complejidad del problema
- El feature engineering fue vital para los resultados del modelo
- Es importante realizar una correcta separación en train y test
- La optimización de hiperparametros resultó muy útil para lograr mejorar la performance de los modelos

Limitaciones

- Es fácil sobreestimar el potencial de un monoplaza dado que se cuenta solo con datos de la mejor vuelta en una serie de condiciones que suelen ser más favorables que las de carrera.

- En general, por el periodo de tiempo elegido, en los datos utilizados se observa un gran dominio de un constructor y piloto lo que dificulta la predicción sobre temporadas con menos dominios de equipos (como 2024).

- Incidentes/accidentes que son externos a los factores analizados (como fallas de fiabilidad, pit stops lentos, choques, descalificaciones por reglamento).

Proximos pasos

- Agregar como categoría que entre en los puntos.
- Elaborar nuevas features que incorporen más información contextual
  - Estrategias de pit stop
  - Datos específicos de los autos
  - Datos climáticos en tiempo real
- Explorar modelos más complejos o avanzados
- Implementar un sistema de actualización continua
- Crear una variante del sistema que tome el grupo completo de corredores, y use eso para predecir el ganador

¡Gracias!
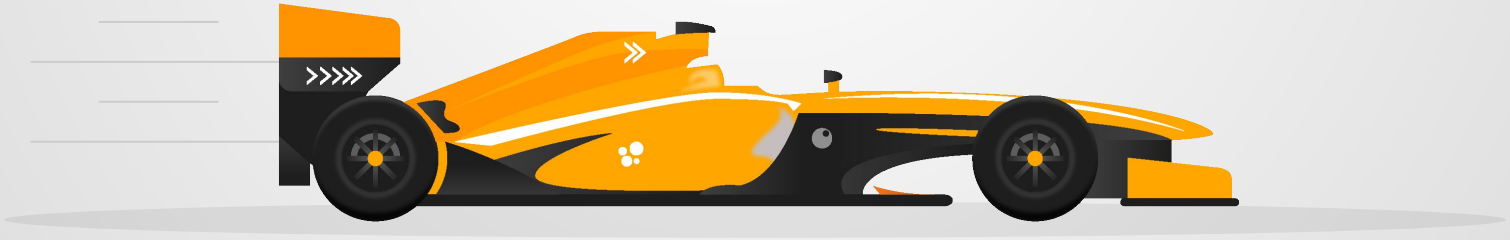
¿Preguntas?